

TASK5 AI 交易引擎：机器学习算法与场景应用

1 分类机器学习算法

1.1 逻辑回归

逻辑回归是常用的分类算法。它先计算特征的线性组合 $z=\beta_0+\beta_1x_1+...+\beta_px_p$ ，再通过 Sigmoid 函数 $p=1/(1+e^{(-z)})$ 把结果映射到 0 至 1 之间，将 p 解释为样本属于正类的概率。若默认阈值为 0.5，则 $p\geq0.5$ 时预测为正类，否则预测为负类。

逻辑回归的优势是计算速度快、能够直接输出概率，而且系数方向便于解释；它适合作为分类任务的基线。局限在于默认决策边界为线性。量化交易中，它可用于预测未来收益是否为正、某个信号是否有效或公司是否进入风险状态。

1.2 决策树

决策树通过不断选择特征和切分阈值，把样本空间划分为更纯的子区域。分类树常用基尼不纯度衡量节点中类别混杂程度，并选择能够最大程度降低不纯度的切分。最终从根节点到叶节点形成一组易读的 if-then 规则。决策树可以拟合非线性关系和变量交互，也不要求特征标准化。

1.3 随机森林

随机森林属于集成学习方法。它对训练数据进行多次 bootstrap 抽样，为每个样本子集训练一棵决策树，并在每次节点划分时只考虑随机抽取的一部分特征。分类时，多棵树对类别投票或对正类概率取平均。样本随机性与特征随机性降低了树之间的相关性，因此集成结果通常比单棵树更稳定。

随机森林能够处理非线性和高阶交互，对异常值和噪声通常也更稳健；代价是模型体量增大、单一预测较难解释。在量化交易中，它适合融合财务、估值、动量、情绪和微观结构特征预测收益方向或风险事件。

1.4 三种算法的比较

表 1 三种分类算法的特点与量化场景

算法	主要特点	优势	局限与量化应用
逻辑回归	线性组合经 Sigmoid 输出概率	速度快、可解释、强基线	难以自动捕捉非线性；适合收益方向或事件概率预测
决策树	按不纯度递归切分形成规则	规则直观、无需标准化	容易过拟合；适合可读的因子条件组合
随机森林	多棵随机树平均概率或投票	稳定、能拟合非线性与交互	解释和计算成本较高；适合多源金融特征融合

2 分类模型评价指标

2.1 混淆矩阵

混淆矩阵把真实类别与预测类别交叉排列。本文统一规定恶性为正类（1）、良性为负类（0），横轴为预测类别、纵轴为真实类别。TN 表示良性被正确预测为良性；FP 表示良性被误判为恶性；FN 表示恶性被漏判为良性；TP 表示恶性被正确识别。明确正类与矩阵方向是解释所有后续指标的前提。

表 2 混淆矩阵与常用指标定义

指标	计算公式	解释
Accuracy	$(TP+TN)/(TP+TN+FP+FN)$	全部样本中分类正确的比例；类别不均衡时可能误导
Precision	$TP/(TP+FP)$	被预测为恶性的样本中，真实恶性的比例
Recall / TPR	$TP/(TP+FN)$	真实恶性样本中，被模型识别出的比例
Specificity	$TN/(TN+FP)$	真实良性样本中，被正确排除的比例
F1	$2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$	Precision 与 Recall 的调和平均
FPR	$FP/(FP+TN)$	真实良性样本中，被错误标记为恶性的比例

2.2 ROC 曲线与 AUC

分类阈值决定概率如何被转换为 0 或 1。不断改变阈值，可以得到不同的 TPR 与 FPR 组合；以 FPR 为横轴、TPR 为纵轴连接这些点，就得到 ROC 曲线。理想模型的曲线靠近左上角，随机分类器的期望表现位于从 (0,0) 到 (1,1) 的对角线上。

AUC 是 ROC 曲线下的面积，也可理解为随机抽取一个正类和一个负类时，模型把正类预测分数排在负类之前的概率。AUC=0.5 表示排序能力接近随机，越接近 1 表示区分能力越强。需要注意，AUC 不直接反映某个固定阈值下的误判数量，也不能代替医学诊断成本、交易手续费、滑点或策略收益分析。

3 Python 实验设计

3.1 数据来源与标签重编码

实验调用 `sklearn.datasets.load_breast_cancer(as_frame=True)` 加载 Wisconsin Diagnostic Breast Cancer 数据。共有 569 条样本、30 个数值特征，无缺失值。`scikit-learn` 原始编码为恶性=0、良性=1；为使风险事件与正类一致，本文使用 `y=1-y_original` 将其重编码为恶性=1、良性=0。全样本含恶性 212 条、良性 357 条。

```
from sklearn.datasets import load_breast_cancer

data = load_breast_cancer(as_frame=True)
X = data.data.copy()
y = 1 - data.target.astype(int) # 恶性=1，良性=0
```

3.2 训练集与测试集划分

使用 `train_test_split` 将数据按 80%/20% 分层划分，`random_state` 固定为 42。训练集 455 条，用于拟合预处理参数和模型参数；测试集 114 条，只用于最终评价。`stratify=y` 使两部分保持近似一致的类别比例。

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.20, stratify=y, random_state=42
)
```




图 1 训练集与测试集类别分布

图 1 显示训练集中良性 285 条、恶性 170 条，测试集中良性 72 条、恶性 42 条。两部分的恶性占比仅相差约 0.52 个百分点，说明分层划分保持了原有类别结构，测试结果不会因为类别比例明显偏移而失真。

3.3 模型设定与训练

表 3 三种模型的实验设定

模型	预处理	主要参数
逻辑回归	StandardScaler Pipeline	solver=liblinear; max_iter=5000; random_state=42
决策树	无	criterion=gin; max_depth=4; min_samples_leaf=5; class_weight=balanced
随机森林	无	n_estimators=500min_samples_leaf=2; class_weight=balanced; random_state=42

逻辑回归的标准化在 Pipeline 内完成，因此 StandardScaler 只在训练集上拟合，避免把测试集均值和标准差提前泄漏给模型。树模型不依赖距离或梯度尺度，不需要标准化。所有模型均输出预测类别和恶性正类概率，后者用于 ROC 与 AUC 计算。

3.4 评价方法与不确定性

测试集采用默认 0.5 阈值计算混淆矩阵、Accuracy、Precision、Recall、Specificity 和 F1；AUC 使用 predict_proba 输出的恶性概率计算，而不是使用离散的 0/1 预测类别。为描述有限测试样本带来的不确定性，本文对测试集进行 2,000 次有放回 bootstrap，并取 AUC 分布的 2.5% 与 97.5% 分位数作为 95% 区间。

4 模型结果与解读

4.1 综合评价结果

表 4 三种分类模型的测试集评价结果

评价指标	逻辑回归	决策树	随机森林
Accuracy	97.37%	91.23%	97.37%
Precision	97.56%	90.00%	100.00%
Recall	95.24%	85.71%	92.86%
Specificity	98.61%	94.44%	100.00%
F1	96.39%	87.80%	96.30%
AUC	0.9960	0.9203	0.9974
AUC 95%区间	[0.987, 1.000]	[0.847, 0.979]	[0.991, 1.000]

表 4 显示，逻辑回归与随机森林的测试集准确率均为 97.37%。随机森林 AUC 最高，为 0.9974，逻辑回归以 0.9960 紧随其后；两者的 bootstrap 区间高度重叠，不能据此断言随机森林在总体上必然更优。决策树 AUC 为 0.9203，明显低于另外两个模型，且 Recall 只有 85.71%。

4.2 逻辑回归混淆矩阵




图 2 逻辑回归测试集混淆矩阵

图 2 中 $TN=71$ 、 $FP=1$ 、 $FN=2$ 、 $TP=40$ 。逻辑回归只把 1 个良性样本误判为恶性，并漏判 2 个恶性样本。其 Recall 为 95.24%、Specificity 为 98.61%，说明默认阈值下对两类样本的识别较均衡。

4.3 决策树混淆矩阵




图 3 决策树测试集混淆矩阵

图 3 中 $TN=68$ 、 $FP=4$ 、 $FN=6$ 、 $TP=36$ 。决策树的错误总数为 10 个，其中 6 个恶性样本被漏判，使 Recall 降至 85.71%。虽然树深已受到限制，训练 AUC 仍为 99.16%，测试 AUC 只有 92.03%，二者差距为三种模型中最大，体现了单棵树较高的过拟合敏感性。

4.4 随机森林混淆矩阵




图 4 随机森林测试集混淆矩阵

图 4 中 $TN=72$ 、 $FP=0$ 、 $FN=3$ 、 $TP=39$ 。随机森林没有把任何良性样本误判为恶性，因此 Precision 和 Specificity 均为 100%；但它漏判了 3 个恶性样本，Recall 为 92.86%，略低于逻辑回归。如果漏判代价显著高于误报代价，可以下调概率阈值以提高 Recall。

4.5 ROC 曲线与 AUC 比较

图 5 三种分类模型的 ROC 曲线




图 5 三种分类模型的 ROC 曲线

图 5 显示随机森林与逻辑回归的 ROC 曲线几乎贴近左上角，AUC 分别为 0.997 和 0.996，说明两者对恶性和良性样本均有很强的排序区分能力。决策树曲线明显更接近随机基准，AUC 为 0.920。不过 AUC 不指定实际分类阈值，最终模型仍需结合 FP 与 FN 成本选择阈值。