

从规则策略到机器学习选股

量化交易实践总结与多策略系统设计

作者：李子平

完成日期：2026 年 7 月 22 日

摘要

本文综合前六项课程任务，围绕数据获取、技术指标、规则策略、机器学习建模与组合回测，构建可复现的量化研究路径。研究比较双均线和海龟策略在十只跨行业股票上的样本外表现，并将通用机器学习流程迁移至中证 300 样本的季度收益排序。结果显示，5 日/15 日双均线在六成股票上取得正收益，但仅一只跑赢买入持有；海龟策略可降低回撤，却存在明显的标的和参数敏感性。决策树选股组合累计净收益为 30.04%，低于 48.42% 的样本等权基准，平均排序相关亦为负。报告据此认为，策略复杂度不能替代数据时点、样本外检验、基准比较和风险约束，并提出由机器学习选股、趋势确认、波动率定仓与组合监控组成的多策略框架。

关键词：量化交易；趋势跟踪；双均线；海龟策略；机器学习选股；样本外回测；风险管理

目录

摘要	2
1 量化交易核心概念与研究框架	4
1.1 从数据到决策的完整链条	4
1.2 核心价值、评价原则与研究边界	4
1.3 六项任务形成的递进式学习路线	5
2 量化交易策略综合分析	6
2.1 技术指标是信息压缩工具而非独立答案	6
2.2 双均线策略具有趋势捕捉能力但超额收益不足	6
2.3 海龟策略以风险预算换取更平稳的损失路径	8
2.4 不同策略的适用场景、关联性与互补性	9
2.5 多策略量化交易系统的构建思路	10
3 机器学习在量化交易中的应用总结	11
3.1 从通用分类实验到金融预测问题	11
3.2 数据预处理、特征工程与防止信息泄漏	12
3.3 模型选择、训练与评价	12
3.4 机器学习选股取得正收益但未形成稳定超额	13
3.5 机器学习的优势、局限与发展趋势	15
4 结论与展望	16

4.1 主要结论	16
4.2 学习收获与能力提升	16
4.3 后续研究计划	16
参考文献	16
附录 改进建议	17

1 量化交易核心概念与研究框架

1.1 从数据到决策的完整链条

量化交易是把投资假设转化为可计算、可执行和可检验规则的研究与交易方法。完整过程并不止于生成买卖信号，而是从数据获取和清洗开始，经由特征或指标构造、信号生成、仓位配置、成本建模、回测评价，再进入模拟执行和持续监控。任何一个环节出现时间错位、数据遗漏或口径不一致，都可能让表面优秀的结果失去可信度。

TASK1 以寒武纪日线为例，保存了未复权与前复权价格，共 242 个交易日，覆盖 2025 年 7 月 4 日至 2026 年 7 月 3 日。复权处理使跨分红送转时期的收益计算保持连续。TASK2 进一步对平安集团和三一重工的本地行情进行缺失值检查和描述性统计，共形成 18 条字段级统计记录，并计算相对强弱、指数平滑异同移动平均、布林带和平均真实波幅等指标。两项任务共同说明，量化策略首先是一项数据工程工作。

六项任务形成的量化研究闭环




图 1 六项任务形成的量化研究闭环

图 1 将学习成果重新组织为数据、指标、规则策略、机器学习和组合决策五个阶段。TASK1 与 TASK2 构成数据和特征基础，TASK3 与 TASK4 验证规则策略，TASK5 建立机器学习评价流程，TASK6 完成金融场景中的模型选股与组合回测。

1.2 核心价值、评价原则与研究边界

量化交易的核心价值主要体现在四个方面：第一，用明确规则减少临场情绪对交易决策的影响；第二，使假设可以在历史样本中重复检验；第三，在多资产和多指标环境中保持一致执行；第四，把收益目标与仓位、回撤和成本约束放在同一框架内。其价值不是保证盈利，而是提高决策的可解释性、纪律性和可审计性。

评价策略时，本报告遵循“收益、风险、基准、稳定性”四维框架。收益使用累计收益和年化收益描述；风险使用波动率、最大回撤和夏普比率刻画；基准用于回答策略是否比被动持有更

有效；稳定性则通过样本外区间、跨股票表现、参数敏感性和交易成本情景进行检查。对于机器学习模型，还必须区分预测指标与投资指标：预测排序正确不必然产生可交易的超额收益。

研究边界：TASK3 与 TASK4 使用相同的十只股票和相近样本区间，但仓位机制不同；TASK6 使用不同股票池和季度频率。因此本报告比较的是方法机制与样本外证据，不把三类策略的累计收益直接做横向排名。

1.3 六项任务形成的递进式学习路线

表 1 TASK1-TASK6 的学习成果与报告角色

任务	主要内容	形成的能力
TASK1	行情获取与复权	理解数据来源、复权和可复现保存
TASK2	技术指标与质量检查	把价格和成交信息转化为可解释指标
TASK3	双均线趋势策略	掌握信号延迟、成本和样本外比较
TASK4	海龟突破与风险定仓	把波动率、止损和风险预算纳入策略
TASK5	通用机器学习分类	建立预处理、训练、评价与过拟合检查流程
TASK6	机器学习季度选股	完成金融特征、时间划分、组合回测与成本敏感性

表 1 体现了从单项工具到完整研究系统的递进关系。前两项任务解决“数据能否使用”，中间两项解决“规则能否执行”，后两项解决“模型能否泛化并转化为组合收益”。这种组织方式也构成后文的直线型行文逻辑。

2 量化交易策略综合分析

2.1 技术指标是信息压缩工具而非独立答案

TASK2 中的相对强弱指标反映上涨与下跌动能的相对强度，指数平滑异同移动平均用于观察趋势动量，布林带描述价格相对均值和波动区间的位置，平均真实波幅则衡量价格波动而不判断方向。这些指标把长序列压缩为易解释的状态变量，但都存在滞后、参数依赖或市场状态敏感性，因此不应把单一阈值机械理解为确定买卖指令。

从后续任务看，技术指标有三种更合理的使用方式：作为规则策略的组成部分、作为风险管理尺度、作为机器学习特征。双均线将移动平均转化为趋势方向信号；海龟策略用平均真实波幅确定仓位和止损距离；TASK6 则将动量、趋势、风险和流动性变量共同输入模型。由此，指标的价值来自其在完整决策链中的功能，而不是指标名称本身。

2.2 双均线策略具有趋势捕捉能力但超额收益不足

TASK3 在五个行业、十只股票上实施双均线策略。信号在收盘后生成，下一交易日才应用仓位，并计入单边 0.1% 的综合交易成本，从而避免把信号当日已经发生的收益错误计入策略。默认 5 日/15 日参数在样本外的累计收益中位数为 31.9%，夏普比率中位数为 0.57，最大回撤中位数为 -27.6%；60% 的股票取得正收益，但只有 10% 跑赢对应的买入持有基准。

5日/15日双均线策略与买入持有基准




图 2 5日/15日双均线策略与买入持有基准

图 2 直接展示策略和基准的样本外累计收益。长电科技、宁德时代等标的上的策略收益为正，但多数情况下仍落后于买入持有；贵州茅台和五粮液等标的则出现负收益。该结果说明“避免部分下跌”和“创造稳定超额收益”是两个不同问题。

表 2 双均线参数的样本外跨股票中位表现

均线窗口	累计收益	夏普比率	最大回撤	正收益占比	买入次数
5 日/15 日	31.9%	0.57	-27.6%	60%	23.5
20 日/60 日	18.7%	0.41	-26.5%	60%	6.5
10 日/30 日	17.3%	0.39	-28.2%	70%	12.0
10 日/20 日	15.8%	0.36	-28.7%	60%	17.5
5 日/10 日	4.9%	0.21	-27.2%	60%	32.0

表 2 显示，5 日/15 日参数在当前股票池上的夏普比率中位数最高，但不同参数的排序并不构成未来最优证明。短周期信号更灵敏、交易次数更多，也更容易受到震荡噪声和交易成本影响；长周期信号较平滑，但会延迟进入和退出。

双均线参数的样本外夏普比率




图 3 双均线参数的样本外夏普比率

图 3 进一步揭示股票与参数之间的交互。同一个均线窗口在半导体、新能源、银行和食品饮料股票上的结果可能方向相反，因此从单只股票挑选历史最优参数容易产生数据挖掘偏差。参数选择应优先关注跨标的和滚动样本外稳定性。

2.3 海龟策略以风险预算换取更平稳的损失路径

TASK4 使用 20 日突破入场、10 日通道退出、20 日平均真实波幅和 2 倍波动止损。每笔交易的计划风险控制为账户权益的 1%，因而仓位会随波动率上升而下降。默认参数在样本外有 70% 的股票取得正收益，累计收益中位数为 0.6%，夏普比率中位数为 0.08，最大回撤中位数为 -5.8%，平均风险敞口中位数仅为 7.4%。较低回撤既来自止损，也来自较低资金暴露。

表 3 海龟策略参数的样本外跨股票中位表现

参数组合	累计收益	夏普比率	最大回撤	正收益占比	平均敞口
40 日入场/20 日退出/2 倍止损	2.8%	0.30	-5.9%	70%	7.7%
10 日入场/5 日退出/1.5 倍止损	3.8%	0.30	-7.2%	60%	9.1%
20 日入场/10 日退出/3 倍止损	1.4%	0.19	-4.4%	60%	5.1%
20 日入场/10 日退出/1.5 倍止损	2.1%	0.19	-8.0%	60%	9.2%
20 日入场/10 日退出/2 倍止损	0.6%	0.08	-5.8%	70%	7.4%
55 日入场/20 日退出/2 倍止损	-0.7%	-0.06	-5.5%	40%	6.4%

表 3 中，40 日入场、20 日退出、2 倍波动止损的夏普比率中位数相对较高，但它并非对所有股票占优。更长通道可以过滤部分噪声，却可能错过趋势前段；更窄止损容易被正常波动触发，更宽止损则降低仓位并扩大单笔容忍区间。参数必须与资产波动和组合分散程度共同评价。

2.4 不同策略的适用场景、关联性与互补性

相同股票上的规则策略风险调整收益




图 4 相同股票上的规则策略样本外夏普比率

图 4 使用相同股票的样本外夏普比率比较双均线和海龟策略。双均线收益分化更大，海龟策略在多数标的上的数值更接近零。由于两者资金暴露不同，该图主要用于观察稳定性和适用差异，不能视为严格的组合归因实验。

表 4 三类策略的优缺点、适用场景与互补角色

策略	信号来源	适用场景	主要优点	主要局限	系统角色
双均线	短长期均线交叉	持续趋势、交易成本较低	规则简单、方向清晰	震荡期反复交易、接近全仓	中期方向过滤
海龟策略	价格通道突破	趋势扩张、可跨资产分散	ATR 定仓与止损完整	低胜率、跳空和成交限制	入场确认与风险控制
机器学习选股	多因子横截面排序	股票数量较多、因子关系稳定	可处理非线性和交互	过拟合、漂移和弱可解释性	候选股票筛选

三类方法的互补性来自决策维度不同，而不是简单平均收益。机器学习回答“优先持有哪些股票”，双均线回答“中期方向是否允许持有”，海龟突破和平均真实波幅回答“何时确认入场

以及承担多大风险”。但这种互补关系目前只是结构性假设，必须在统一股票池、交易频率和成本口径下重新回测。

2.5 多策略量化交易系统的构建思路




图 5 多策略量化交易系统的建议架构

图 5 提出五层系统：先使用历史可交易股票池和点时数据建立研究底座，再用机器学习完成横截面筛选，以均线和突破规则过滤逆势信号，用平均真实波幅确定仓位和止损，最后在组合层监控收益、回撤、换手、相关性和模型漂移。具体实施顺序见附录建议 A5。

表 5 多策略系统的模块与职责

模块	核心输入或工具	主要职责
数据层	股票池、行情、公司行为、成交状态	保证每个信号时点只使用当时可得数据
选股层	多因子排序模型	输出候选股票及预测分数
择时层	均线方向、通道突破	减少逆势持仓并定义执行时点
风险层	波动率定仓、止损、行业约束	控制单股和组合损失集中度
执行层	换手、费用、涨跌停和容量	把理论信号转化为可成交订单
监控层	净值、回撤、相关性、漂移	识别策略失效并触发降权或复核

3 机器学习在量化交易中的应用总结

3.1 从通用分类实验到金融预测问题

TASK5 使用 569 条医学示例数据和 30 项数值特征，按分层随机方式划分训练集与测试集，比较逻辑回归、决策树和随机森林。该任务的意义在于建立标准机器学习流程，包括缺失检查、标准化、模型训练、混淆矩阵、准确率、召回率和曲线下面积评价。由于数据不是金融数据，实验结果只能证明流程能够正确运行，不能用来支持交易策略有效性。

通用分类实验中的模型评价




图 6 通用分类实验中的模型评价

图 6 显示逻辑回归和随机森林在该示例数据上的测试集表现较高，单棵决策树相对较弱。这个结果同时提示：模型优劣依赖数据结构和评价目标。进入金融场景后，类别准确率不再是唯一目标，模型还必须接受时间顺序、收益排序和交易成本的检验。

表 6 TASK5 通用分类实验的测试集指标

模型	准确率	精确率	召回率	调和平均	曲线下面积	训练测试差
逻辑回归	97.4%	97.6%	95.2%	96.4%	99.6%	1.5%
决策树	91.2%	90.0%	85.7%	87.8%	92.0%	5.0%
随机森林	97.4%	100.0%	92.9%	96.3%	99.7%	2.6%

3.2 数据预处理、特征工程与防止信息泄漏

TASK6 将机器学习流程迁移到股票横截面收益排序。研究从抓取时点的中证 300 当前成分列表中等距抽取 120 只股票，取得 2015 年 1 月至 2026 年 7 月的 294,312 条后复权日线，形成 4,281 条股票-季度记录和 18 项动量、趋势、风险及流动性因子。训练期为 2016 年第一季度至 2023 年第一季度，验证期为随后四个季度，测试期为 2024 年第二季度至 2026 年第一季度。

防止信息泄漏的关键是让数据可得时间早于信号，信号早于建仓，建仓早于收益标签结束。TASK6 在每个季度末形成特征，在下一季度初建仓，并用再下一季度初的价格计算持有期收益；测试期逐季使用扩展窗口重新训练。横截面缩尾、缺失填补和百分位转换也仅使用当期股票，避免把未来分布带回历史。该设计比随机打乱金融样本更符合真实决策过程。

数据局限：TASK6 使用当前成分股回溯历史，而不是逐季度历史成分股，存在幸存者与样本选择偏差；历史 ST、停牌、涨跌停和冲击成本也未完整模拟。相关改进见附录建议 A3 与 A4。

3.3 模型选择、训练与评价

岭回归提供线性和正则化基准，决策树能够学习非线性阈值，随机森林通过多棵树的抽样平均降低单树方差。模型在验证期选择参数，再在测试期逐季度重训。预测层使用平均绝对误差、均方根误差、决定系数和季度排序相关系数；策略层使用累计收益、年化收益、波动率、夏普比率、最大回撤、换手率、跟踪误差和信息比率。

金融预测通常具有低信噪比。决定系数为负说明模型在点预测层面可能不如简单均值，但排序相关性仍可能对选股有价值；反过来，平均排序相关性略高也不保证前 30 名组合能跑赢基准，因为组合只使用分布上端，容易受到极端个股、行业集中和换手成本影响。因此模型选择必须同时检查统计指标和经济结果。

三种模型的测试期季度排序相关性




图 7 三种模型的测试期季度排序相关性

图 7 显示三种模型的季度排序相关性波动明显。决策树的测试期平均值为-0.080，仍是三种模型中相对最高者，且仅一半季度为正。该证据不支持“模型已经形成稳定预测优势”，更合理的解释是模型信号较弱并存在市场状态依赖。

3.4 机器学习选股取得正收益但未形成稳定超额

表 7 TASK6 模型预测与前 30 名组合回测结果

模型	平均秩相关	正相关季度	累计净收益	年化收益	夏普比率	最大回撤	年化超额
岭回归	-0.137	25%	9.7%	4.7%	0.36	-10.5%	-17.1%
决策树	-0.080	50%	30.0%	14.0%	0.83	-8.3%	-7.8%
随机森林	-0.097	38%	22.7%	10.8%	0.71	-7.1%	-11.0%

表 7 显示，决策树前 30 名组合在单边 0.2%综合成本下累计净收益为 30.04%、年化收益为 14.04%、最大回撤为-8.29%。同期研究样本等权基准累计收益为 48.42%，说明组合虽然获得正绝对收益，却没有形成正超额收益。

机器学习选股组合与基准的累计净值




图 8 机器学习选股组合与基准的累计净值

图 8 给出决策树组合和研究样本等权基准的复利路径。策略在部分季度控制了下跌，但整体净值终点低于基准。仅观察 30.04%的正收益容易产生乐观判断，加入基准后才能识别策略的机会成本。

机器学习选股组合与基准的回撤路径




图9 机器学习选股组合与基准的回撤路径

图9说明策略评价还需要考虑路径风险。决策树组合最大回撤约为8.29%，低于其累计收益规模，但较小回撤不能抵消长期落后基准的问题。组合若要进入实盘模拟，必须同时满足超额收益、回撤和稳定性要求。

3.5 机器学习的优势、局限与发展趋势

机器学习的优势是能够在大量特征中拟合非线性关系和交互作用，并通过统一评分完成横截面排序；它还可以与滚动训练、特征重要性和模型集成结合，适应不断更新的数据。其局限则包括过拟合、标签噪声、数据泄漏、模型漂移、可解释性不足和交易成本放大。金融市场中的数据分布会随制度、参与者和风险偏好变化，模型历史成功并不意味着结构长期稳定。

未来更值得探索的方向不是继续增加模型复杂度，而是提高证据质量：使用逐季度真实股票池和公告日对齐的财务数据，扩大样本外区间，进行行业和风格中性化，比较滚动与扩展窗口，加入特征稳定性筛选，并用组合级风险预算约束模型输出。模型还应设置漂移阈值和停用规则，使“何时不相信模型”成为系统的一部分。

4 结论与展望

4.1 主要结论

第一，量化交易的专业性首先体现在研究流程，而非策略名称。复权、时间顺序、基准、成本和风险口径决定了结果是否可信。第二，双均线和海龟策略都能在部分趋势阶段工作，但跨股票差异和参数敏感性显著，单一规则难以适应所有市场。第三，机器学习能够形成系统化选股流程，却没有在当前样本中产生稳定的排序能力和超额收益。第四，多策略系统的价值应来自选股、择时和风险控制的职责分工，并需要组合级样本外验证。

核心判断：策略有效性的最低标准不是“回测赚钱”，而是在真实可得数据、合理成本和样本外检验下，相对明确基准取得与风险相匹配的稳定增量。

4.2 学习收获与能力提升

通过六项任务，我完成了从调用数据接口、处理复权价格和检查数据质量，到计算技术指标、编写交易规则、设计无前视回测、评价策略风险，再到训练机器学习模型和构建季度组合的完整实践。相比只关注模型输出，学习过程中更重要的提升是能够追踪每个数字的来源，识别看似优秀结果背后的口径差异，并主动报告负面证据和研究限制。

在专业表达方面，本报告将分散任务重新组织为一条因果清晰的研究路线，并通过统一图表说明结果。报告没有回避双均线多数情况下未跑赢持有基准、海龟策略绝对收益有限以及机器学习平均排序相关为负等事实。这种对结果边界的说明，是从完成程序走向完成研究的重要一步。

4.3 后续研究计划

后续工作将按“先修正数据，再统一回测，最后增加复杂度”的顺序推进。第一阶段建立历史可交易股票池和真实成本模型；第二阶段在同一股票池、同一调仓日和同一风险预算下复测双均线、海龟与机器学习组合；第三阶段开展多策略权重和市场状态识别；第四阶段建立模拟交易监控，记录信号、订单、成交、偏差和策略漂移。附录建议 A1-A6 给出了相应的实施要点。

参考文献

- [1] Breiman, L. (2001). Random Forests. *Machine Learning*, 45, 5-32.
- [2] Fama, E. F., & French, K. R. (1993). Common risk factors in the returns on stocks and bonds. *Journal of Financial Economics*, 33(1), 3-56.
- [3] Gu, S., Kelly, B., & Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *Review of Financial Studies*, 33(5), 2223-2273.
- [4] TuShare 与 AkShare 公开接口文档；本报告使用的数据抓取日期和实际来源记录见各任务的数据元文件。

附录 改进建议

建议 A1 统一策略比较口径

对应问题：TASK3 采用接近全仓的仓位切换，TASK4 采用 1%风险预算，TASK6 则按季度等权选股，累计收益无法直接比较。改进措施：选定共同股票池、共同样本外区间、共同成本和共同目标波动率，对各策略输出进行波动率缩放后再比较收益、回撤、换手和相关性。预期效果：区分信号质量与资金暴露差异。优先级：高。正文引用：第 1.2 节、第 2.4 节。

建议 A2 建立滚动样本外与参数稳定性检验

对应问题：当前参数比较仍可能受到特定样本区间影响。改进措施：使用滚动训练窗口和固定长度测试窗口，记录每期最优参数、次优参数以及参数邻域表现；只有在多个窗口和多个标的上均不过度失真的参数才进入候选集。预期效果：降低数据挖掘和参数过拟合。优先级：高。正文引用：第 2.2 节、第 2.3 节。

建议 A3 使用点时股票池与公告日数据

对应问题：TASK6 使用当前中证 300 成分股回溯历史，可能遗漏已被剔除或退市股票。改进措施：按每个季度恢复当时的指数成分、上市状态和风险警示状态；财务和估值特征严格按公告日加入，避免使用事后修订数据。预期效果：降低幸存者偏差和信息泄漏。优先级：最高。正文引用：第 3.2 节。

建议 A4 完善交易可达性与成本模型

对应问题：现有回测未完整模拟停牌、涨跌停、整手、滑点、印花税变化和市场冲击。改进措施：建立订单级执行规则，以信号后可成交价格为基准，按成交额比例估计冲击成本，并对不同资金规模进行容量情景分析。预期效果：缩小理论收益与模拟实盘收益的差距。优先级：高。正文引用：第 3.2 节、第 3.4 节。

建议 A5 验证机器学习选股与趋势风控的组合

对应问题：本报告提出的多策略架构尚未进行统一实证。改进措施：先由模型选出前 30 名股票，再分别测试无择时、均线过滤和通道突破三种入场规则；所有方案使用相同的平均真实波幅风险预算和行业上限，并比较净超额、最大回撤、换手和回撤恢复时间。预期效果：验证互补性是否真实存在。优先级：中高。正文引用：第 2.5 节。

建议 A6 建立策略监控和停用机制

对应问题：回测不能自动识别上线后的结构变化。改进措施：持续监控滚动排序相关、超额收益、回撤、换手、特征分布和策略间相关性；当指标连续越过预设阈值时，自动降权、停止新增仓位并触发研究复核。预期效果：把模型失效风险转化为可执行流程。优先级：中高。正文引用：第 2.5 节、第 3.5 节。